

Création de la Base de Données de la Série Friends

1. Présentation du projet

1.1. Contexte

Date de début : 27/09/2024 | Date de fin : 17/01/2025

1.2. Objectifs

Le but de ce projet est de :

- Effectuer du scrapping pour récupérer les données sur Internet
- Alimenter la base de données afin de pouvoir effectuer des requêtes pour répondre aux questions posées suivants :
 - Les saisons et épisodes de la série, y compris les résumés et les liens entre eux.
 - Les personnages principaux et leurs relations, y compris les acteurs qui les jouent et les guest stars qui apparaissent dans les épisodes.
 - Les lieux des épisodes et leur contexte dans l'univers de la série.
 - Les relations amoureuses et les membres de la famille des personnages principaux.

1.3. Livrables

Les principaux livrables du projet sont :

- **Modèle Conceptuel de Données (MCD)**, conçu pour une gestion efficace des relations complexes entre les entités (personnages, acteurs, épisodes, etc.).
- **Code SQL :**
 - Création des tables: avec des relations bien définies pour garantir l'intégrité des données.
 - Requetes SQL: pour tester et vérifier la base, et pour répondre aux questions complexes sur la série.
- **Code Python :**
 - Scrapping des données: via BeautifulSoup et Selenium pour récupérer les informations nécessaires depuis des sources fiables comme Wikipédia et FanFR.
 - Alimentation de la base de données: à l'aide de psycopg2, avec une vérification systématique des données insérées.

2. Démarche du Projet

Le projet a été mené en plusieurs étapes cruciales :

- **Recherche des sources** : L'une des premières étapes importantes a été l'identification de sites fiables pour collecter des données, comme [Wikipedia](#) et [FanFR](#). Cela nous a permis d'accéder à des informations complètes et actualisées.

Sélection d'invités

Les Célébrités
Toutes les stars ayant joué un rôle dans la série.

Les Incontournables
Tous les personnages clés sans qui Friends ne serait pas tout à fait la même série.

Les personnages récurrents
Tous les personnages que l'on retrouve dans plusieurs épisodes.

Les personnages notoires
Tous les personnages joués par des acteurs connus dans le monde du cinéma ou de la télévision et tous les personnages n'apparaissant que dans un seul épisode mais ayant une importance particulière.

Les personnages proches
Tous les personnages que l'on ne voit que dans un seul épisode mais qui font partie de l'univers proche de l'un des six Friends (famille, petit-ami, ami ou collègue).

Les personnages anodins
Tous les personnages que l'on ne retrouve que dans un seul épisode sans avoir de rôle majeur.

- **Création du MCD** : Un modèle conceptuel de données a été élaboré en prenant en compte les entités principales (acteurs, personnages, épisodes, saisons) et leurs relations. Ce modèle a été réalisé sous deux formes : en étoile et en flocon, assurant ainsi une structure de base de données flexible et bien normalisée.

```
MCD
saison = (id_saison INT, nom_saison VARCHAR(50), resume_saison TEXT, annee_saison DATE);
episode = (id_episode INT, num_episode INT, nom_episode VARCHAR(50), resume_episode TEXT, #id_saison);
personnage = (id_personnage INT, prenom_personnage TEXT, nom_personnage VARCHAR(50), date_naissance_personnage DATE);
acteur = (id_acteur INT, nom_acteur VARCHAR(50), prenom_acteur VARCHAR(50), statut_invite VARCHAR(50), date_naissance_acteur DATE);
relation = (id_relation INT, type_relation VARCHAR(50));
pays = (id_pays INT, nom_pays VARCHAR(50));
site_web = (id_site INT, nom_site VARCHAR(50));
ville = (id_ville INT, nom_ville VARCHAR(50), #id_pays);
lieu = (id_lieu INT, nom_lieu TEXT, #id_ville);
interpreter = (#id_personnage, #id_acteur);
contenir = (#id_episode, #id_personnage);
se_situer = (#id_episode, #id_lieu);
lier = (#id_episode, #id_personnage, #id_personnage 1, #id_relation);
noter = (#id_episode, #id_site, note_episode DECIMAL(4,2), nb_votant VARCHAR(50));
evaluer = (#id_saison, #id_site, note_saison DECIMAL(4,2), nb_votes INT);
```

- **Scrapping des données** : J'ai utilisé BeautifulSoup pour extraire les informations des pages web, et Selenium pour naviguer sur des pages dynamiques avec des liens supplémentaires. Cette double approche a permis d'extraire les données de manière efficace et complète.
- **Nettoyage des données** : Un script Python a été utilisé pour uniformiser

- **Création et alimentation de la base de données :** Une fois les données nettoyées et structurées, j'ai utilisé psycopg2 pour insérer les données dans la base de données PostgreSQL, en garantissant l'intégrité des informations à chaque étape.
- **Vérification la base de données :** Des requêtes SQL ont été utilisé pour tester

The screenshot shows a PostgreSQL query editor interface. The top section is titled 'Query' and contains a SQL query. Below the query is a 'Data Output' section showing the result of the query.

Query:

```

1  SELECT COUNT (DISTINCT ller.id_personnage)
2      FROM relation
3      INNER JOIN ller
4      ON ller.id_relation = relation.id_relation
5      INNER JOIN personnage
6      ON ller.id_personnage_1 = personnage.id_personnage
7      WHERE nom_personnage = 'Bing'
8      AND type_relation = 'Petit%20Ami'

```

Data Output:

	count bigint
1	12

Un exemple pour répondre à la question Chanler a eu combien de petites amies?.

3. Conclusion

En conclusion, ce projet a permis de créer et d'alimenter une base de données dédiée à la série Friends, en intégrant des données variées comme les personnages, les acteurs, les épisodes et les saisons.

Grâce à une démarche méthodique incluant le scrapping, le nettoyage des données, et leur insertion dans une base relationnelle, nous avons atteint nos objectifs principaux. Les outils comme Python, Selenium, et PgAdmin ont joué un rôle crucial dans le traitement des données et la gestion des tables.

Enfin, les tests réalisés confirment l'intégrité et la pertinence des données, offrant ainsi une base solide pour répondre à des requêtes complexes sur l'univers de la série.