

Analyse des Déterminants de l'Espérance de Vie

Contexte du Projet

Réalisée dans le cadre de la **SAÉ 4.02** (Expliquer ou prédire une variable quantitative à partir de plusieurs facteurs), cette étude vise à identifier et modéliser les facteurs socio-économiques et sanitaires qui influencent l'espérance de vie à travers le monde.

- **Données utilisées** : Jeu de données fusionné de l'OMS (Observatoire mondial de la santé) et des Nations Unies, couvrant 193 pays sur la période 2010-2015.


- **Périmètre** : 860 observations et 13 variables clés (santé, économie, démographie).

L'espérance de vie ne dépend pas uniquement des soins médicaux, mais est fortement corrélée à la scolarisation et au statut économique global. Malgré certaines limites liées à la non-normalité des résidus, les modèles développés offrent une base solide pour comprendre et prédire les tendances de santé publique mondiale.

Modèle complet

Test	Test utilisé	P_value
La normalité	Shapiro-Wilk test	9.848e-10
L'homoscédasticité	Breusch-Pagan	0.0004124
L'autocorrélation	Durbin-Watson	2.2e-16

Résultat des tests



Graphiques des résidus

=> Violations importantes des hypothèses de la régression

Objectifs et Méthodologie

L'objectif principal était de construire le modèle de prédiction le plus performant pour l'espérance de vie en suivant une démarche analytique rigoureuse :

1. **Analyse Exploratoire** : Étude univariée (distribution de l'espérance de vie) et bivariée (corrélations) pour détecter les colinéarités.
2. **Régression Linéaire Simple** : Modélisation de l'impact de la **scolarisation**, suivie d'un ajustement par suppression des points aberrants (outliers) pour améliorer la précision.
3. **Régression Linéaire Multiple** : Utilisation de méthodes de sélection de variables (**Descendante, Ascendante et Pas à pas**) pour isoler les facteurs les plus significatifs.
4. **Analyse de la Variance (ANOVA)** : Étude de l'impact du statut économique (Développé, Émergent, En développement) sur la santé des populations.

Résultats Clés

- **Impact de la Scolarisation** : Le modèle simple ajusté a démontré que chaque année supplémentaire de scolarisation augmente l'espérance de vie d'environ **2,29 ans**, expliquant à elle seule **76,6 %** de la variabilité de la santé globale.
- **Optimisation du Modèle** : Les trois méthodes de sélection de variables ont convergé vers un modèle optimal à **8 variables** (incluant la mortalité adulte, le VIH/SIDA, l'IMC et la vaccination contre la diphtérie), atteignant un **R² ajusté de 0,818**.
- **Disparités Économiques** : L'ANOVA a confirmé une hiérarchie marquée : les pays développés affichent une espérance de vie moyenne de **80,8 ans**, contre **68,8 ans** pour les pays en développement, soit un écart significatif de 12 ans.

Compétences Techniques Déployées

- **Nettoyage de données** : Identification et traitement de 145 points aberrants via les résidus standardisés.
- **Tests d'hypothèses statistiques** : Validation des modèles par les tests de **Shapiro-Wilk** (normalité), **Breusch-Pagan** (homoscédasticité) et **Durbin-Watson** (indépendance).
- **Modélisation prédictive** : Estimation de l'espérance de vie avec intervalles de confiance à 95 %.
- **Outils** : Programmation statistique et analyse de variance (ANOVA) avec comparaisons multiples (méthodes PPDS et Bonferroni).